

Costes operativos anuales

Escenario: 1.000 médicos registrados · uso intensivo (DeepSeek + MegaCuaderno + ScanIA)

Cartagenaeste · Área II Cartagena · Carlos Galera Román · **Fecha:** 26 abril 2026 · **Versión:** Sentry plan free

Asunciones del modelo

Métrica	Valor
Médicos registrados (MAU)	1.000
DAU activos / día (30%)	300
Peticiones askAi / médico activo / día	40
Imágenes ScanIA / médico activo / día	5
MegaCuadernos / médico activo / día	1
Volumen mensual askAi (clínico + educational)	~315.000 llamadas
Volumen mensual visión (ScanIA)	~45.000 imágenes
Volumen mensual MegaCuaderno (output ~5k tokens)	~9.000
Cache hit rate efectivo (no-vision)	25%
Tokens promedio · clinical/educational (in/out)	1.500 / 1.200
Tokens promedio · visión (in con imagen / out)	~2.300 / 800
Tokens promedio · MegaCuaderno (in/out)	2.000 / 5.000

1. Costes de inteligencia artificial

Mayor partida (~87% del total). Coste por token, output cuesta ~4× más que input. Modelos de visión (Qwen 2.5-VL) ~6× más caros que DeepSeek por token.

Concepto	Volumen / mes	USD / mes	EUR / año
Casos clínicos · DeepSeek V3 paid	270.000	\$465	5.000 €
Educational · DeepSeek V3	45.000	\$77	830 €
Visión ScanIA · Qwen 2.5-VL 72B	45.000	\$315	3.400 €
MegaCuaderno (output 5k tokens) · DeepSeek	9.000	\$54	580 €
Subtotal directos		\$911	9.810 €
Con cache 25% + markup OpenRouter +15%		\$805	8.700–9.700 €

2. Firebase / Google Cloud (core)

Stack base: Auth, Cloud Functions (askAi en europe-west1), Firestore, Cloud Storage. Mayoritariamente dentro del free tier; los pequeños excedentes son razonables a este volumen.

Recurso	EUR / mes	EUR / año
Firebase Auth · 1.000 MAU	5,00	60
Cloud Functions · invocaciones (3M facturables)	1,10	13
Cloud Functions · GB-s excedente	1,20	14
Firestore · reads / writes (free tier mensual sobra)	<0,10	1
Firestore · storage (10–20 GiB)	3,30	40
Cloud Storage · backups diarios + retención	1,20	14
Egress · descargas / exports / PDFs (50–80 GiB/mes)	8,80	105
Subtotal Firebase / GCP core	~21	~250–300

3. Otros costes (algunos no obvios)

Concepto	EUR / año	Detalle
Cloud Logging excedente	250–300	1.000 MAU intensivos generan 80–150 GiB de logs/mes; free son 50 GiB. Mitigable.
Sentry (plan free)	0	Hasta 5.000 events/mes gratis; si superas, deja de aceptar (no cobra automático).
Artifact Registry (imágenes Cloud Functions Gen2)	12	Almacenamiento de la imagen del runtime. Despreciable.
Secrets Manager (~5 secrets)	4	0,06 USD/secret/mes. Despreciable.
Reserved instance askAi (minInstances=1)	11	Pago aunque idle para evitar cold start clínico.
Backup Cloud Storage retención larga (Archive)	24	Lifecycle a Archive abarata mucho la retención > 90 días.
Dominio area2cartagena.es	15	Renovación anual.
Cloud Monitoring (uptime + 8 alertas)	0–25	Free hasta 1M checks/mes; sobra para producción.
Email transaccional (si SendGrid/Mailgun)	0	Firebase Auth incluye magic-link sin coste adicional.
Seguro RC profesional + ciber	400–900	Obligatorio para venta a hospitales / B2B sanitario.
Subtotal otros	~700–1.300	

4. Total operativo anual

Bloque	Realista	Pesimista
IA (DeepSeek + Qwen-VL + MegaCuaderno)	8.700–9.700	11.500–13.000
Firebase / GCP core	250–300	350–400
Cloud Logging excedente	250–300	400–500
Sentry (plan free)	0	0
Pequeños (Artifact, secrets, reserved, dominio)	70	90
Backup Cloud Storage retención larga	24	30
Seguro RC profesional + ciber	400–900	900
TOTAL	9.700–11.300 €	13.700–16.700 €

Distribución del coste (escenario realista)

Concepto	% del total
IA (DeepSeek + Qwen-VL)	≈ 87 %
Cloud Logging	≈ 3 %
Firebase core	≈ 3 %
Seguro RC + ciber	≈ 6 %
Pequeños / backup / dominio	≈ 1 %

5. Margen operativo según pricing

Pricing por médico	Ingreso bruto / año	Margen sobre coste realista
15 € / médico / mes (180 €/año × 1.000)	180.000 €	94 %
10 € / médico / mes (120 €/año × 1.000)	120.000 €	91 %
5 € / médico / mes (60 €/año × 1.000)	60.000 €	83 %

Por qué se dispara el coste a este volumen

- 1. Pagas por token, no por usuario.** Cada palabra que entra y sale de la IA cuesta. La salida cuesta ~4× más que la entrada. Una pregunta corta consume × 1, un MegaCuaderno (~3.500 palabras de salida) consume × 7, una imagen ScanIA + análisis × 10.
- 2. ScanIA es el ítem más caro.** Qwen 2.5-VL (visión) cuesta 6× más que DeepSeek por token. Procesar una imagen equivale a ~1.500 palabras de input solo en la imagen. 5 fotos / día / médico × 300 activos × 30 días = 45.000 imágenes / mes ≈ 3.400 €/año.
- 3. Multiplicas por 300, no por 1.** Una petición individual cuesta céntimos. Pero con 300 médicos activos haciendo 40 preguntas / día = 370.000 llamadas / mes. Lo barato × 370.000 = 8.700 €/año.
- 4. Logs y observabilidad escalan también.** Cloud Logging tiene 50 GiB free / mes; 1.000 médicos intensivos generan ~100 GiB. El excedente son ~250 €/año.

Recomendaciones para optimizar costes

Sin perder valor clínico:

- Limitar cuotas ScanIA (ej. 3 imágenes / día / médico) → ahorra ~1.300 €/año.
- Mantener cache hash 7d en MegaCuaderno (ya activo) → bien.
- Usar Gemini Flash-Lite en lugar de Qwen-VL para fotos sencillas → ~70% más barato.
- Filtrar logs de bajo valor con sink en logger → ahorra ~250 €/año.

Si se necesita reducir más agresivamente:

- Plan Anthropic Claude Haiku 4.5 como primario (5 USD / 1M output) podría ser más barato que Qwen-VL para visión sencilla.
- Revisar cuota dura por médico (50 / día actual) — si es excesiva, bajarla.